



**Universidade Federal da Paraíba
Campus I**

Bacharelado de Ciência da Computação

Relatório Elaboração do Algoritmo de Detecção de Respondentes Descuidados

Este documento busca resumir o processo de elaboração do algoritmo de detecção de respondentes descuidados. Ele explica os métodos implementados no caso de estudo, assim como sugestões de futuras adições ao algoritmo. [link do código](#).

1. Metodologia

O procedimento adotado tem como objetivo identificar padrões de resposta potencialmente associados a **careless responding**, também denominado *insufficient effort responding* (IER). Esse fenômeno ocorre quando o participante responde ao questionário sem o nível esperado de atenção ou esforço, podendo produzir padrões artificiais, excessivamente repetitivos ou incompatíveis com a estrutura estatística dos itens.

A literatura recomenda evitar a dependência de um único indicador, porque diferentes formas de resposta descuidada podem produzir padrões distintos. Por exemplo, um respondente pode repetir uma alternativa por longos períodos, enquanto outro pode responder de forma aleatória. Um indicador pode detectar bem o primeiro comportamento e ser pouco eficaz para o segundo. Por essa razão, abordagens de **múltiplos indicadores** ou *multiple-hurdle* são utilizadas para aumentar a abrangência da triagem.

Neste estudo foram utilizados três indicadores:

1. **LongString**, para identificar repetição excessiva de uma mesma categoria em itens consecutivos;
2. **Distância de Mahalanobis**, para identificar padrões multivariadamente atípicos;

3. **Índice de person-fit (I_z)**, para verificar se o padrão individual de respostas é compatível com um modelo de Teoria de Resposta ao Item (IRT).

A decisão final utiliza a lógica de **multiple-hurdle**: um participante é sinalizado quando ultrapassa pelo menos uma das barreiras.

2. LongString Analysis

2.1. O que é

O **LongString** mede a maior sequência consecutiva de respostas idênticas dada por um respondente.

Por exemplo:

3 3 3 3 2 4 1 5

possui:

LongString=5

Já:

2 2 2 1 1 4 4 4 5

possui:

LongString=4

A lógica é que um respondente cuidadoso tende a considerar o conteúdo de itens diferentes, enquanto uma sequência extremamente longa da mesma alternativa pode indicar que o participante deixou de considerar individualmente os itens.

O LongString é uma das medidas clássicas de **response invariability** e aparece com frequência na literatura sobre careless responding.

2.3. Por que o limite foi definido como 50%?

O ponto de corte adotado foi:

$$\text{LONGSTRING_THRESHOLD} = \text{int}(\text{len}(\text{item_cols}) * 0.50) + 1$$

Como existem 54 itens:

Como existem 54 itens:

$$54 \times 0,50 = 27$$

e:

$$27+1=28$$

Logo:

$$LS_i \geq 28$$

É considerado uma violação da barreira LongString.

A escolha de **mais da metade da escala** veio da literatura. Curran é citado na literatura como uma referência para usar, como ponto inicial, uma sequência superior a metade do comprimento da escala.

3. Distância de Mahalanobis

3.1. Objetivo

Enquanto o LongString procura **repetição excessiva**, a distância de Mahalanobis procura **padrões multivariadamente atípicos**.

Cada respondente é representado por um vetor:

$$\mathbf{x}_i = (x_{i1}, x_{i2}, \dots, x_{i54})$$

Por exemplo, para um respondente:

$$[4, 5, 4, 3, 4, \dots, 2]$$

O procedimento compara esse vetor com o centro da distribuição dos respondentes.

3.2. Fórmula

A distância de Mahalanobis ao quadrado é:

$$D_i^2 = (\mathbf{x}_i - \bar{\mathbf{x}})^T S^{-1} (\mathbf{x}_i - \bar{\mathbf{x}})$$

onde:

- $\mathbf{x}_i$ = vetor de respostas do participante;
- $\bar{\mathbf{x}}$ = vetor de médias dos itens;
- S = matriz de covariâncias dos itens;
- S^{-1} = inversa da matriz de covariâncias.

A utilização da matriz de covariâncias é justamente o que diferencia Mahalanobis de uma simples distância Euclidiana: correlações entre itens são consideradas.

A literatura de careless responding descreve Mahalanobis como uma técnica de detecção de outliers multivariados e a utiliza como indicador de padrões de resposta atípicos.

3.3. Por que foi utilizada a distribuição χ^2 ?

Sob condições de normalidade multivariada, a distância de Mahalanobis ao quadrado possui, assintoticamente, distribuição qui-quadrado com número de graus de liberdade correspondente ao número de variáveis:

$$D^2 \sim \chi_p^2$$

A literatura metodológica faz exatamente essa conexão ao descrever Mahalanobis para detecção de respostas atípicas.

No presente estudo:

$$D^2 \sim \chi_p^2$$

A partir disso pode-se selecionar um quantil da distribuição como ponto de corte. Neste estudo foi escolhido o quantil de 99,9% como critério conservador.

4. Person-Fit

4.1. Objetivo

O person-fit parte de uma pergunta diferente:

O padrão de respostas desse indivíduo é plausível segundo o modelo psicométrico que descreve os itens?

Diferentemente do Mahalanobis, que compara o indivíduo com a distribuição empírica dos respondentes, o person-fit compara a resposta observada com as **probabilidades esperadas segundo um modelo IRT**.

Foi utilizado o índice:

$$I_z$$

O I_z foi proposto por **Drasgow, Levine e Williams (1985)** e é um dos índices de person-fit mais estudados. O trabalho original tratou explicitamente de modelos poliatômicos/polytômicos, o que é particularmente relevante para itens Likert.

Estudos posteriores e revisões continuam tratando I_z como um dos principais índices de person-fit.

4.2 Por que utilizar um modelo GRM?

Os itens utilizados são:

1 = discordo totalmente

2 = discordo

3 = neutro

4 = concordo

5 = concordo totalmente

Ou seja, possuem **categorias ordenadas**.

O **Graded Response Model (GRM)** é um modelo IRT desenvolvido para itens com categorias ordenadas.

O modelo estima como a probabilidade de cada categoria varia em função de um traço latente θ .

Em termos simplificados:

$$P(X_{ij} = k \mid \theta_i)$$

representa a probabilidade de o respondente i , com nível latente θ_i , fornecer a categoria k no item j .

Consequentemente, a probabilidade esperada para cada resposta deixa de ser simplesmente "cada alternativa possui a mesma chance". Ela passa a depender de:

- características do item;
- posição do respondente no traço latente;
- estrutura das categorias.

Isso fornece uma referência estatística para avaliar se o padrão individual é plausível.

4.3 Como o l_z é calculado?

Primeiro calcula-se a log-verossimilhança do padrão observado:

$$l_0 = \sum_j \log P(X_{ij} = x_{ij} \mid \theta_i)$$

Depois calcula-se sua expectativa e variância sob o modelo.

O índice padronizado é:

$$l_z = \frac{l_0 - E(l_0)}{\sqrt{\text{Var}(l_0)}}$$

Essa é a estrutura formal apresentada na literatura sobre l_z .

Um l_z muito negativo significa que o padrão observado possui uma probabilidade menor do que seria esperada pelo modelo.

Em termos intuitivos:

$$l_z \ll 0$$

indica **person-misfit**.

4.4 Correção de Bonferroni

Foram considerados:

N=930

respondentes completos.

O nível global escolhido foi:

$\alpha=0,05$

que é um nível de significância convencional em inferência estatística.

Para evitar que a realização de 930 testes simultâneos aumente demasiadamente a probabilidade de falsos positivos, foi utilizada a correção de Bonferroni:

$$\alpha_{\text{individual}} = \frac{0,05}{930}$$

resultando em:

$$0,00005376$$

Portanto, o participante é sinalizado quando:

$$p_i < 0,00005376$$

Isso equivale, sob a aproximação normal usada, a aproximadamente:

$$l_z < -3,873$$

Esse procedimento é mais defensável do que escolher manualmente, por exemplo, $l_z < -2$ ou $l_z < -3$.

5. Possíveis extensões do algoritmo

Embora o algoritmo desenvolvido utilize os indicadores LongString, distância de Mahalanobis e índice de person-fit ($|z_l - z_z|$), seria interessante incorporar, em trabalhos futuros, outros métodos para a detecção de respondentes descuidados. A utilização conjunta de diferentes indicadores pode ampliar a capacidade de identificar comportamentos inadequados, uma vez que cada método avalia uma característica distinta do padrão de respostas.

5.1. Psychometric Synonyms/Antonyms

Uma possibilidade seria adicionar o método baseado em **psychometric synonyms/antonyms**, que consiste em analisar a consistência das respostas dadas a questões semanticamente relacionadas.

No caso de questões consideradas sinônimas, espera-se que o participante forneça respostas semelhantes ou compatíveis. Por exemplo, duas questões podem avaliar praticamente a mesma característica utilizando formulações diferentes. Quando as respostas apresentadas são muito discrepantes, isso pode indicar que o participante não considerou adequadamente o conteúdo dos itens.

Por outro lado, questões consideradas antônimas ou objetivamente contrárias devem apresentar um padrão de resposta inverso. Assim, se uma questão afirma uma característica positiva e outra apresenta uma afirmação claramente negativa sobre o mesmo aspecto, espera-se que as respostas sejam coerentes após a

aplicação da recodificação necessária. Respostas incompatíveis entre esses itens podem ser utilizadas como evidência de possível careless responding.

A aplicação desse método exige, entretanto, uma etapa prévia de validação do conteúdo do questionário. É necessário identificar com segurança:

- pares de questões que sejam semanticamente equivalentes ou sinônimas;
- pares de questões que expressem ideias objetivamente contrárias;
- a necessidade de recodificação dos itens formulados em sentido inverso;
- o grau de discrepância entre as respostas que será considerado indicativo de descuido.

Esse procedimento não foi incorporado ao algoritmo atual porque não havia certeza suficiente sobre quais questões poderiam ser classificadas, de maneira objetiva e defensável, como sinônimas ou antônimas. Uma classificação inadequada poderia produzir falsos positivos, sinalizando respondentes cuidadosos apenas porque os itens não eram realmente equivalentes ou opostos. Portanto, a inclusão desse indicador deve ser precedida por uma análise semântica e psicométrica dos itens, preferencialmente com base em avaliação de especialistas ou em evidências empíricas de validade.

5.2 Tempo de resposta

Outro método potencialmente útil seria a análise do **tempo total de resposta ao questionário**. A lógica desse indicador é identificar participantes que concluíram o instrumento em um período extremamente inferior ao tempo normalmente observado entre os respondentes.

Um tempo muito curto pode sugerir que o participante não leu adequadamente as questões, respondeu de forma automática ou selecionou alternativas sem considerar o conteúdo dos itens. Para implementar esse procedimento, seria necessário estabelecer uma referência de tempo considerado normal. Essa referência poderia ser obtida a partir da distribuição dos tempos de resposta dos participantes, utilizando, por exemplo:

- a mediana e o intervalo interquartil;
- percentis inferiores da distribuição;
- um limite definido a partir de um grupo de respondentes considerado válido;
- uma estimativa do tempo mínimo necessário para a leitura e o preenchimento dos itens.

Esse método não foi adicionado ao algoritmo atual porque sua utilização exigiria configurações específicas no formulário para registrar adequadamente o tempo de preenchimento. O que não é possível fazer, visto que as respostas já foram registradas.

5.3 Attention Check ou Instructed Response Item

Uma terceira possibilidade seria incluir uma questão de atenção, conhecida como Attention Check ou Instructed Response Item. Esse tipo de item contém uma instrução explícita para que o participante selecione uma alternativa específica, independentemente do conteúdo substantivo da pergunta.

Um exemplo seria:

“Para confirmar que você está lendo atentamente, selecione a opção ‘Concordo’ nesta questão.”

Nesse caso, a questão não tem como objetivo medir o construto principal do questionário. Sua finalidade é verificar se o participante está acompanhando as instruções apresentadas. O respondente que selecionar uma alternativa diferente daquela indicada poderá ser desclassificado ou sinalizado para análise posterior.

Esse método é particularmente direto, pois a regra de classificação é simples: o participante que responder incorretamente ao item de atenção não atende ao critério estabelecido.

A inclusão desse procedimento não foi realizada no presente estudo porque seria necessário acrescentar uma nova pergunta ao questionário e modificar a configuração do formulário antes da coleta dos dados. Como o instrumento já havia sido aplicado sem esse item, não seria possível recuperar posteriormente essa informação para os respondentes existentes.

6. Referências Bibliográficas

- <https://www.sciencedirect.com/science/article/abs/pii/S0022103115000931?via%3Dihub>
- <https://pmc.ncbi.nlm.nih.gov/articles/PMC10552731>
- <https://edoc.unibas.ch/entities/publication/5e567dcd-2bde-429b-989c-267bad5f27d0>
- https://www.researchgate.net/publication/224050661_Identifying_Careless_Responses_in_Survey_Data
- <https://journals.sagepub.com/doi/10.1177/25152459251378420>
- <https://www.appliedclinicaltrialsonline.com/view/anticipating-careless-responders-in-survey-design-and-analysis>
- https://osf.io/preprints/psyarxiv/zf79q_v1