



**Universidade Federal da Paraíba
Campus I**

Bacharelado de Ciência da Computação

Relatório Aplicação de Machine Learning na base de dados: Pesquisa contínua sobre o profissional brasileiro de TI atuante no país

Este documento busca resumir o processo de aplicação de Machine learning. Ele explica como os modelos foram criados e treinados e os resultados obtidos. [link do código](#).

1. Metodologia e Construção do Modelo

1.1 Objetivo da análise

O objetivo foi investigar quais características pessoais, profissionais e comportamentais estão associadas à satisfação profissional e utilizar essas informações para construir um modelo capaz de estimar a resposta da questão Q50:

“Eu me sinto satisfeito(a) com meu atual cargo/função.”

O objetivo principal não foi apenas desenvolver um modelo preditivo, mas compreender quais questões apresentavam maior relevância para a estimativa da Q50, referente à satisfação do participante com seu cargo ou função atual. Dessa forma, buscou-se identificar os aspectos mais associados à satisfação profissional de trabalhadores da área de Tecnologia da Informação.

1.2 Construção do Modelo

Os dados foram padronizados e transformados para facilitar sua utilização no modelo. Variáveis como idade, experiência em TI, tempo no cargo e mudanças de empregador foram convertidas para formatos numéricos ou ordinais. Os cargos foram agrupados em categorias amplas, as questões de múltipla escolha foram transformadas em indicadores binários e os valores ausentes foram tratados conforme o tipo de variável.

A questão Q50, que representa a satisfação profissional, foi definida como variável-alvo e retirada dos preditores. Após a remoção de respostas inválidas, os dados foram divididos de forma estratificada em treinamento, validação e teste, correspondendo a aproximadamente 60%, 20% e 20% da amostra.

Foi utilizado o **CatBoostRegressor**, por sua capacidade de trabalhar com variáveis numéricas e categóricas. O modelo foi treinado com até 2.000 iterações, taxa de aprendizagem de 0,03, profundidade máxima de 5 e mecanismo de *early stopping* para reduzir o risco de sobreajuste.

O desempenho foi avaliado pelas métricas **MAE**, que mede o erro médio das previsões; **RMSE**, que penaliza erros maiores; e **R²**, que indica a proporção da variação da satisfação explicada pelo modelo. Também foram utilizadas as correlações de Pearson e Spearman para medir associações entre variáveis, além dos valores SHAP para interpretar a contribuição de cada variável nas previsões.

Idealmente, as questões deveriam ser agrupadas em conjuntos menores de acordo com os construtos ou temas avaliados, reduzindo a quantidade de colunas utilizada pelos modelos e tornando a análise mais simples e estável. Entretanto, essa agregação não foi realizada porque não havia segurança suficiente sobre quais questões deveriam compor cada grupo, e um agrupamento inadequado poderia misturar conceitos diferentes ou eliminar informações relevantes.

2. Resultados


2.1 Distribuição da variável-alvo

A distribuição da satisfação profissional foi relativamente equilibrada entre os cinco níveis da escala. No conjunto de treinamento, aproximadamente 10,5% dos participantes responderam 1, 12,0% responderam 2, 25,2% responderam 3, 26,7% responderam 4 e 25,6% responderam 5. As distribuições dos conjuntos de validação e teste permaneceram muito semelhantes devido à divisão estratificada.

Esse equilíbrio relativo é positivo para o treinamento, pois reduz o risco de o modelo aprender predominantemente uma única categoria. Ainda assim, a variável-alvo é ordinal e foi tratada como numérica em um problema de regressão. Essa escolha permite prever valores intermediários, mas não representa explicitamente a natureza ordinal da escala.

2.2 Correlação de Pearson

A análise de Pearson identificou as seguintes variáveis entre as maiores associações positivas com a satisfação Q50:




A interpretação mais direta é que a satisfação tende a ser maior entre participantes que demonstram motivação de carreira, percepção positiva do ambiente, confiança técnica e avaliação favorável do próprio desempenho.

Entretanto, as correlações são moderadas. Nenhuma variável isolada apresentou associação suficientemente alta para explicar sozinha a satisfação profissional. Isso indica que a satisfação provavelmente resulta de vários fatores simultâneos, incluindo aspectos individuais, profissionais, organizacionais e contextuais

2.3 Correlação de Spearman

A correlação de Spearman apresentou um ranking semelhante, mas com algumas diferenças na ordem das variáveis. Entre as maiores associações positivas apareceram:



A principal vantagem de Spearman, neste caso, é avaliar relações monotônicas utilizando os postos das variáveis. Como os itens Likert são ordinais, essa medida pode ser mais adequada do que assumir que as distâncias entre as categorias 1, 2, 3, 4 e 5 são perfeitamente equivalentes.

No entanto, Spearman também não estabelece causalidade. Por exemplo, a associação entre satisfação e desempenho superior pode ocorrer porque pessoas satisfeitas avaliam


seu desempenho de forma mais positiva, porque o bom desempenho aumenta a satisfação ou porque ambos são influenciados por uma terceira variável.

2.4 Associação negativa da graduação em andamento

Nos gráficos, a variável “graduação em andamento” apresentou associação negativa com a satisfação profissional. Uma explicação plausível é que participantes ainda em formação podem estar em estágio, início de carreira ou em cargos com menor autonomia e remuneração. Nesse caso, a variável educacional pode estar funcionando como um marcador de fase profissional, e não como uma causa direta da insatisfação.

2.5 Interpretação do gráfico SHAP

O gráfico SHAP apresenta como cada variável contribui para as previsões do modelo de Machine Learning CatBoost.



A interpretação geral é:

- valores SHAP positivos deslocam a previsão para uma satisfação maior;
- valores SHAP negativos deslocam a previsão para uma satisfação menor;
- cada ponto representa um participante;
- a cor representa o valor da variável, com azul indicando valores baixos e vermelho indicando valores altos.

Entre as variáveis mais relevantes no gráfico estão a percepção de carga excessiva de trabalho, idade, envolvimento com o trabalho, preferência por regras claras, formação completa, avaliação por supervisores, graduação em andamento, desempenho superior, percepção de descontração e motivação de carreira.

A variável Q57, relacionada à percepção de carga excessiva de trabalho, apresentou ampla dispersão de valores SHAP. Isso sugere que o efeito dessa característica não é simplesmente linear: para diferentes participantes, uma mesma resposta pode produzir impactos distintos dependendo de outras variáveis do perfil.

A idade também apresentou efeitos em direções diferentes. Isso indica que a relação entre idade e satisfação pode depender do contexto profissional, do tempo de experiência, do cargo ou da modalidade de trabalho. Portanto, não é adequado afirmar simplesmente que participantes mais velhos ou mais jovens são necessariamente mais satisfeitos

2.6 Avaliação crítica do modelo

```
===== MÉTRICAS =====  
MAE treino:      0.3849  
MAE validação:   0.9030  
RMSE treino:     0.4792  
RMSE validação:  1.1273  
R² treino:       0.8589  
R² validação:    0.2156
```

A análise das métricas mostrou que o modelo apresentou desempenho insatisfatório na previsão da satisfação profissional. Esse resultado pode estar relacionado à natureza multifatorial da satisfação, ao grande número de variáveis em relação ao tamanho da amostra e ao risco de *overfitting*. O agrupamento das questões em dimensões menores poderia ter reduzido a quantidade de preditores e tornado o modelo mais estável, mas não foi realizado devido à falta de segurança sobre como organizar os itens adequadamente.

Além disso, seria necessário utilizar validação cruzada, testar modelos mais apropriados para a escala ordinal da Q50, aplicar técnicas de seleção e redução de variáveis e realizar uma otimização mais ampla dos hiperparâmetros. Essas melhorias não foram implementadas devido às limitações de tempo do estágio, mas representam possibilidades relevantes para trabalhos futuros.

2.7 Conclusão

Apesar do desempenho preditivo insatisfatório, as análises exploratórias permitiram identificar variáveis associadas à satisfação profissional. Os resultados sugerem que a satisfação está relacionada a um conjunto de condições, e não a uma única característica. Entre os fatores mais consistentes estão:

- motivação para crescer e desenvolver a carreira;
- percepção de um trabalho descontruído;
- envolvimento e engajamento com as atividades;
- confiança para resolver problemas técnicos;
- percepção de bom desempenho;
- interesse em compreender as ferramentas utilizadas;
- relações e avaliações positivas no ambiente de trabalho.

Esses achados devem ser interpretados como associações identificadas na amostra, e não como previsões altamente precisas ou relações causais.

Assim, o modelo foi mais útil como ferramenta exploratória para investigar a relevância relativa das questões do que como instrumento confiável de previsão individual.

